

Trabalho Prático 2

Introdução a Inteligência Artificial

Gabriel Guimarães dos Santos Ricardo - 2024024062
João Pedro Moreira Smolinski - 2024023996

Junho 2026

Conteúdo

1	Introdução e Objetivo	2
2	Metodologia	2
2.1	k-Nearest Neighbors (kNN)	2
2.2	k-Means	2
2.3	Ferramentas e Decisões de Projeto	3
3	Experimentos e Resultados	3
3.1	k-Nearest Neighbors (kNN)	3
3.2	k-Means	3
4	Discussão	4
4.1	Análise do Aprendizado Supervisionado	4
4.2	Análise do Aprendizado Não-Supervisionado	4
5	Conclusão	5

1 Introdução e Objetivo

A documentação deste trabalho procura abordar a implementação e a análise de algoritmos de aprendizado de máquina, explorando tanto técnicas de aprendizado supervisionado quanto não-supervisionado. Mais especificamente, o estudo foca no desenvolvimento dos algoritmos k – *Nearest Neighbors* (kNN) e k – *Means*.

Para a realização dos experimentos, utilizou-se o conjunto de dados NBA Rookie Stats, que consiste em 1.340 observações contendo variáveis estatísticas de jogadores novatos da NBA (como total de jogos, minutos jogados, pontos, rebotes, entre outros). A variável de interesse neste contexto é a `TARGET_5Yrs`, um rótulo binário que indica se a carreira do jogador durou pelo menos 5 anos na liga (valor 1) ou não (valor 0).

O objetivo principal do trabalho divide-se em três frentes de desenvolvimento e análise:

Aprendizado Supervisionado: Utilizar o algoritmo kNN para prever a variável resposta com base nas estatísticas de jogo dos novatos, avaliando o desempenho do modelo em dados de teste não utilizados durante o treinamento.

Aprendizado Não-Supervisionado: Aplicar o algoritmo k-Means para agrupar os jogadores em diferentes grupos (clusters) utilizando estritamente os atributos que não fossem da coluna alvo, a fim de verificar se as similaridades numéricas geram grupos que possuem alguma relação com a longevidade da carreira dos atletas.

Comparação Analítica: Validar as implementações desenvolvidas pelo grupo comparando-as diretamente com os modelos padronizados da biblioteca `scikit-learn` do Python.

Por meio dessas etapas, este relatório apresenta a metodologia utilizada, experimentos e resultados obtidos e discute o comportamento e a eficácia dos algoritmos no contexto trabalhado.

2 Metodologia

Para a construção deste trabalho, a metodologia baseou-se na implementação nativa dos algoritmos exigidos, desenvolvendo a lógica matemática e computacional de cada método. O foco consistiu em construir modelos funcionais que não dependessem de bibliotecas prontas de aprendizado de máquina para sua execução principal. Nas subseções abaixo, são discutidos os detalhes de implementação de cada algoritmo, as divisões dos dados e as métricas adotadas.

2.1 k-Nearest Neighbors (kNN)

O primeiro modelo implementado foi o algoritmo supervisionado kNN, focado na classificação da variável `TARGET_5Yrs`. Como o kNN é um método de aprendizado baseado em instâncias (lazy learning), o processo de treinamento consistiu apenas no armazenamento das observações de treino.

Para a fase de predição, o algoritmo foi projetado de uma maneira sequencial para cada dado de teste. Primeiramente, o algoritmo calcula a distância euclidiana entre a nova amostra e as amostras previamente armazenadas no conjunto de treino. Depois disso, as distâncias são ordenadas de forma crescente e então os k vizinhos mais próximos são selecionados. Por último, a classe de cada um dos vizinhos selecionados é conferida e a classe mais frequente entre estes é atribuída à nova amostra.

2.2 k-Means

A segunda etapa focou no algoritmo não-supervisionado k-Means, que buscou agrupar os jogadores utilizando estritamente os atributos numéricos das observações, descartando a coluna de resposta original `TARGET_5Yrs`.

A construção desse algoritmo seguiu a literatura clássica (Zaki; Meira Jr, 2020). Inicialmente foram escolhidas k amostras do próprio conjunto para serem os centróides iniciais. O segundo passo foi calcular a distância euclidiana ao quadrado de cada ponto de dados em relação a todos os centróides. Cada observação foi atribuída ao centróide mais próximo. O terceiro passo foi recalculando os centróides

como a média aritmética de todos os pontos de dados atribuídos a este mesmo centróide. O segundo e terceiro passos foram repetidos até um número máximo de vezes previamente estabelecido ou até que a diferença entre os centroides novos e da iteração anterior fosse menor ou igual a uma tolerância predefinida.

Diferentemente do kNN, o k-Means utilizou o conjunto de dados completo (unindo treino e teste) para o agrupamento numérico, com exceção da coluna alvo.

2.3 Ferramentas e Decisões de Projeto

Em conformidade com as restrições do projeto, a lógica computacional de ambos os algoritmos foi escrita do zero. A manipulação das matrizes e o cálculo vetorial das distâncias foram implementados utilizando exclusivamente a biblioteca `numpy`, que garante eficiência computacional em operações matemáticas. A biblioteca `pandas` foi utilizada apenas como auxiliar para a leitura dos arquivos CSV e formatação textual dos resultados para exibição tabular. Por fim, a biblioteca `scikit-learn` foi importada de forma isolada, atuando estritamente na fase de experimentação. Suas classes `KNeighborsClassifier` e `KMeans` serviram como base para atestar a correção matemática das implementações do grupo e prover o comparativo para a seção de resultados.

3 Experimentos e Resultados

Nesta seção, são apresentados os resultados obtidos pela execução dos algoritmos k-Nearest Neighbors (kNN) e k-Means. Para atestar a validade da implementação do grupo, os resultados são colocados lado a lado com as métricas geradas pela biblioteca `scikit-learn`.

3.1 k-Nearest Neighbors (kNN)

O modelo supervisionado foi avaliado no conjunto de teste (20% dos dados) para os valores $k = \{2, 10, 50, 13\}$. A Tabela 1 sintetiza as métricas de desempenho para ambas as implementações.

Tabela 1: Desempenho do kNN (Grupo vs Scikit-Learn)

k	Modelo	Acurácia	Precisão	Recall	F1	Correspondência
2	Grupo	0.5485	0.7327	0.4405	0.5502	99.63%
	Scikit	0.5522	0.7353	0.4464	0.5556	
10	Grupo	0.6306	0.7255	0.6607	0.6916	100.00%
	Scikit	0.6306	0.7255	0.6607	0.6916	
13	Grupo	0.6604	0.7200	0.7500	0.7347	100.00%
	Scikit	0.6604	0.7200	0.7500	0.7347	
50	Grupo	0.6716	0.7326	0.7500	0.7412	100.00%
	Scikit	0.6716	0.7326	0.7500	0.7412	

3.2 k-Means

O modelo não-supervisionado foi testado com todos os dados unidos, descartando a variável alvo `TARGET_5Yrs` durante o treinamento, para $k = \{2, 3\}$. A Tabela 2 e 3 demonstra como os agrupamentos formados organicamente pelos atributos numéricos se relacionam com as classes reais de resposta (0 = reprovou, 1 = durou 5 anos).

Tabela 2: Distribuição das Classes por Cluster ($k = 2$)

Modelo	Cluster	Total de jogadores	Classe 0	Classe 1	Perfil Centróide
Grupo	0	725	160	565	Valores altos para a maior parte das variáveis
	1	615	349	266	Valores baixos para a maior parte das variáveis
Scikit	0	724	160	564	Valores altos para a maior parte das variáveis
	1	616	349	267	Valores baixos para a maior parte das variáveis

Tabela 3: Distribuição das Classes por Cluster ($k = 3$)

Modelo	Cluster	Total de jogadores	Classe 0	Classe 1	Perfil Centróide
Grupo	0	431	267	164	Valores baixos para a maior parte das variáveis
	1	510	125	385	Valores altos para a maior parte das variáveis
	2	399	117	282	Valores médios para a maior parte das variáveis
Scikit	0	495	112	383	Valores altos para a maior parte das variáveis
	1	375	234	141	Valores baixos para a maior parte das variáveis
	2	470	163	307	Valores médios para a maior parte das variáveis

4 Discussão

A partir das métricas e distribuições levantadas na seção anterior, é possível tecer uma análise crítica detalhada sobre o comportamento de ambos os modelos frente ao problema de prever a longevidade da carreira de novatos da NBA.

4.1 Análise do Aprendizado Supervisionado

Observando a Tabela 1, nota-se uma clara tendência de melhora no modelo conforme o valor de k aumenta. Para $k = 2$, o algoritmo obteve sua pior performance (F1 de 0.55). Ao analisar poucos vizinhos, o modelo fica altamente suscetível a ruídos e outliers nos dados de treino.

Conforme a vizinhança é expandida para $k = 10$ e posteriormente para $k = 50$, a acurácia salta para 0.67 e o F1-Score sobe de 0.55 para 0.74. Isso evidencia que considerar o perfil médio de um grupo maior de jogadores com estatísticas semelhantes fornece uma base muito mais sólida para classificar se um novato terá uma carreira longa. Além disso, a precisão manteve-se estável e alta (cerca de 0.73) em quase todos os cenários, indicando que quando o modelo prevê que um jogador durará 5 anos, ele está correto na grande maioria das vezes.

Em termos de validação, as implementações do grupo bateram integralmente (100% de correspondência) com as do scikit-learn para $k \geq 10$. A minúscula diferença em $k = 2$ (99.63%) é provavelmente explicada pelas diferentes políticas de desempate que bibliotecas distintas adotam quando as distâncias euclidianas são exatamente iguais ou quando há empate com exatamente um vizinho de cada classe.

4.2 Análise do Aprendizado Não-Supervisionado

A aplicação do k-Means permitiu analisar se as estatísticas puras do jogo são suficientes para agrupar naturalmente os jogadores em “sucessos” e “fracassos”.

Na implementação com $k = 2$ os jogadores das duas classes estão bastante segregados. O algoritmo não possui o rótulo de resposta, mas ao formar dois grupos, ele separou claramente os jogadores em “Alta Performance” (Cluster 0) e “Baixa Performance” (Cluster 1). O Cluster de Alta Performance agregou jogadores com médias de 73 jogos (GP) e 9 pontos (PTS). Não coincidentemente, os jogadores de alta performance acabam sendo mais longevos na liga, o que contribui para uma maior quantidade de indivíduos da classe 1. Com somente dois clusters, o algoritmo da biblioteca e o desenvolvido pelo grupo têm praticamente a mesma resposta, com apenas um jogador que entrou em um cluster diferente.

Já na implementação com $k = 3$, o k -Means revelou um grupo intermediário de jogadores de “Média Performance”. O cluster 0 agrupou os jogadores com as piores performances, onde a maioria não tem longevidade na liga. O cluster 1 agrupou os jogadores com as melhores performances, onde mais de 75% dos jogadores são longevos. E por fim, o cluster 2 agrupou os jogadores medianos, apesar disso, o número de jogadores longevos também é alto, sendo um reflexo do ambiente da NBA. Para ser longo na liga, nem sempre é necessário ter as melhores métricas possíveis. Ao comparar a implementação do grupo com a implementação do `scikit-learn` com $k = 3$, as diferenças aparecem um pouco mais. Apesar de que em ambos os resultados há 3 grupos parecidos (desempenho baixo, médio e alto), o tamanho dos grupos e os grupos relativos a cada jogador acabaram mudando bastante.

5 Conclusão

Em suma, as implementações propostas e desenvolvidas pelo grupo foram capazes de alcançar com êxito os objetivos estipulados no enunciado do trabalho prático. O uso do algoritmo supervisionado k -Nearest Neighbors demonstrou que prever a longevidade de um jogador na NBA torna-se substancialmente mais assertivo ao avaliar uma vizinhança maior (como $k = 50$). O ambiente estatístico do esporte mostrou que diluir ruídos e analisar tendências de grupos maiores é muito mais eficiente do que confiar em semelhanças isoladas geradas por valores baixos de k .

No escopo não-supervisionado, o algoritmo k -Means evidenciou que as variáveis numéricas do jogo, por si só, possuem peso suficiente para separar organicamente os atletas de elite daqueles que não se firmam na liga. Contudo, ao comparar a implementação do grupo com a biblioteca `scikit-learn` para $k = 3$, as peculiaridades estruturais do algoritmo ficaram evidentes. Apesar de ambos os modelos gerarem três grupos conceitualmente parecidos (desempenho baixo, médio e alto), o tamanho exato dos clusters e os grupos relativos a cada jogador acabaram mudando bastante, provando na prática o quão sensível o método é em relação à inicialização aleatória de seus centróides e a pequenas mudanças na implementação.

Por fim, a altíssima correspondência das previsões do grupo com os resultados de uma biblioteca consolidada de mercado atesta a validade das lógicas matemáticas construídas. O estudo comprova que essas técnicas, mesmo implementadas em suas formas fundamentais, são poderosas para a extração de conhecimento e reconhecimento de padrões em bases de dados complexas e do mundo real.

Referências

ZAKI, Mohammed J.; MEIRA JR, Wagner. **Data Mining and Machine Learning: Fundamental Concepts and Algorithms**. 2. ed. Cambridge: Cambridge University Press, 2020.